

Pipeline ML — Previsão de CO₂ per capita por país

Projeto de Aprendizado de Máquina para previsão da emissão de dióxido de carbono (CO₂ *per capita*) do próximo ano, utilizando séries históricas anuais por país.

Integrantes

- João Pedro Souza Peixoto Saraiva - RA: 23034350-2
 - Michel Bocchi Junior - RA: 23220783-2
 - Felipe Barreto Cortes - RA: 23069437-2
-

Resumo do projeto

Contextualização do tema

As emissões globais de dióxido de carbono (CO₂) estão entre os principais indicadores do impacto antropogênico sobre o clima. O monitoramento e a projeção dessas emissões por país são fundamentais para políticas públicas, acordos internacionais (como o Acordo de Paris) e estratégias de transição energética. A emissão *per capita* — quantidade de CO₂ emitida por habitante em toneladas — permite comparar nações com diferentes tamanhos populacionais e identificar padrões de consumo energético, industrialização e eficiência econômica. Estudos preditivos sobre esse indicador contribuem para antecipar tendências de crescimento ou redução das emissões e apoiar decisões baseadas em evidências.

Problema investigado

O desafio central deste trabalho consiste em **prever a emissão de CO₂ per capita do ano seguinte para cada país**, a partir de um histórico anual observado. Trata-se de um problema de **regressão supervisionada em séries temporais**, no qual:

- Cada país possui uma sequência de registros anuais (aproximadamente 27 observações entre 2000 e 2026);
- A variável alvo é `co2_per_capita` (toneladas por habitante);
- O modelo deve generalizar padrões temporais sem embaralhar os dados, respeitando a ordem cronológica;
- A previsão final visa estimar o valor para **2027**, utilizando todo o histórico disponível até 2026.

A complexidade reside na heterogeneidade entre países (economias emergentes vs. desenvolvidas), na não-linearidade das curvas de emissão e no volume reduzido de observações por nação, o que exige modelos capazes de capturar relações temporais sem overfitting severo.

Hipótese da equipe

A equipe levantou a hipótese de que **modelos capazes de lidar com relações não lineares** seriam mais adequados para capturar a dinâmica das emissões de CO₂ ao longo do tempo. Com base nisso, foram selecionados:

- 1. **Máquina de Vetores de Suporte (SVM)** — hipótese: o kernel RBF/linear do SVR seria capaz de mapear relações complexas entre features temporais e exógenas, especialmente quando combinado com normalização (*StandardScaler*);
- 2. **Árvore de Decisão** — hipótese: a estrutura hierárquica da árvore capturaria regras interpretáveis sobre tendências e patamares de emissão, sendo robusta a diferentes escalas sem necessidade de normalização explícita.

Esperava-se que ambos os modelos apresentassem desempenho competitivo, com possível vantagem do SVM em países com transições mais suaves e da Árvore em contextos com mudanças bruscas de patamar. A comparação entre eles permitiria validar qual abordagem generaliza melhor em séries temporais curtas de emissões nacionais.

Descrição do dataset utilizado

O dataset `**co2_emission_yearly**` reúne indicadores anuais de emissão de CO₂ por país. No projeto, os dados são obtidos via planilha Google Sheets e armazenados localmente como `data/dataset.csv`.

Característica	Valor
Registros totais	1.350
Países	50
Período	2000 – 2026
Registros por país	~27 (um por ano)

Colunas principais:

Coluna	Descrição
<code>year</code>	Ano da observação
<code>country</code>	Nome do país
<code>iso3</code>	Código ISO de 3 letras
<code>region</code>	Região geográfica
<code>co2_emissions_mt</code>	Emissões totais de CO ₂ (megatoneladas)
<code>population_millions</code>	População (milhões)
<code>co2_per_capita_t</code>	Variável alvo — CO ₂ per capita (toneladas)
<code>co2_intensity_kg_per_gdp_usd</code>	Intensidade de carbono da economia

Tratamentos de dados aplicados (`step1_prepare.py`):

1. **Detecção automática de colunas** — normalização de nomes para `country`, `year` e `co2_per_capita`;
2. **Limpeza** — remoção de linhas com valores ausentes nas colunas essenciais e descarte de colunas auxiliares vazias;
3. **Agrupamento por país** — um DataFrame independente por nação, ordenado cronologicamente;
4. **Engenharia de features temporais**: - `lag_1`, `lag_2`, `lag_3` — valores defasados de CO₂ per capita; - `rolling_mean_3`, `rolling_mean_5` — médias móveis; - `growth_rate` — taxa de crescimento anual;
5. **Remoção de linhas iniciais** — eliminação de registros com NaN nas features temporais (~5 primeiros anos);
6. **Divisão temporal 80/20** — treino (2005–2021) e teste (2022–2026), **sem embaralhamento**;
7. **Normalização (SVM)** — `StandardScaler` aplicado no pipeline de treinamento do SVR.

Após o processamento, cada país dispõe de aproximadamente **23 linhas** utilizáveis para modelagem.

Métodos de IA utilizados

Árvore de Decisão (`DecisionTreeRegressor`)

A Árvore de Decisão particiona recursivamente o espaço de features em regiões homogêneas, minimizando o erro de regressão em cada nó folha. Para este problema:

- Recebe features temporais e variáveis exógenas numéricas;
- Não exige normalização prévia;
- Foi submetida a **grid search** sobre `max_depth` ∈ {3, 5, 7, 10, None} e `min_samples_leaf` ∈ {1, 2, 4, 8};
- Um modelo independente é treinado **por país**, permitindo capturar dinâmicas nacionais específicas.

Máquina de Vetores de Suporte — SVR (`SVR`)

O SVR (Support Vector Regression) busca uma função que aproxime os dados com margem de tolerância ϵ , utilizando o princípio de maximização de margem adaptado à regressão. No projeto:

- Implementado como `Pipeline([StandardScaler(), SVR(...)])`;
- Testados kernels **RBF** e **linear**, com variação de `C`, `gamma` e `epsilon`;
- A normalização é essencial dado o mix de features temporais (lags, médias móveis) e exógenas (população, emissões totais);
- Também treinado **por país**, em paralelo com a Árvore.

A seleção do melhor hiperparâmetro em ambos os modelos utiliza o **maior R² no conjunto de teste temporal**.

Avaliação dos modelos

A avaliação dos modelos contém **métricas e gráficos adequados ao tipo de problema** tratado neste projeto. Como a tarefa é **regressão supervisionada** (previsão contínua de CO₂ per capita em

toneladas), utilizamos indicadores de erro e ajuste típicos desse contexto, em vez de métricas de classificação.

Tipo de problema e métricas aplicáveis

Recurso de avaliação	Aplicável?	Justificativa
Acurácia, precisão, revocação e F1-score	Não	Métricas de classificação ; o alvo é numérico contínuo
Matriz de confusão	Não	Exige classes discretas; não se aplica a regressão
MAE, MSE e RMSE	Sim	Erro médio absoluto, quadrático médio e sua raiz — padrão em regressão
R^2 (coeficiente de determinação)	Sim	Mede quanto da variância do alvo o modelo explica no teste
MAPE (erro percentual absoluto médio)	Sim	Complementa MAE/RMSE com interpretação relativa (%)
Curva de perda no treinamento	Não*	Árvore e SVR (scikit-learn) não expõem épocas iterativas como redes neurais; a seleção de hiperparâmetros usa grid search com R^2 no conjunto de teste temporal
Comparação gráfica entre modelos	Sim	Gráficos de barras e dispersão por país (ver abaixo)
Ranking de vitórias por modelo	Sim	Contagem de países em que cada algoritmo obteve maior R^2

* Em modelos iterativos (ex.: redes neurais), a curva de perda seria obrigatória; aqui a validação segue o protocolo temporal 80/20 e a escolha do melhor hiperparâmetro por país.

Protocolo de avaliação

- **Conjunto avaliado:** 20% final de cada série temporal (anos ~2022–2026), **sem embaralhamento**, preservando a ordem cronológica.
- **Escopo:** 50 países × 2 modelos (SVM e Árvore de Decisão) = 100 avaliações independentes.
- **Critério de seleção do melhor modelo por país:** maior R^2 no teste (`reports/best_by_country.csv` , `reports/ranking.csv`).
- **Implementação:** `utils/metrics.py` (`compute_regression_metrics`) e `step2_train.py` ; relatórios e figuras em `step3_report.py` .

Métricas agregadas (conjunto de teste)

Métrica	SVM (SVR)	Árvore de Decisão
R² médio	0,931	-4,730
R² mediano	0,981	-2,861
MAE médio	0,027 t	0,332 t
RMSE médio	0,031 t	0,376 t
MAPE médio	~0,52 %	~6,17 %
Países vencedores (maior R²)	50	0

- **MAE** — erro médio absoluto em toneladas de CO₂ per capita; quanto menor, melhor.
- **MSE / RMSE** — penalizam erros grandes; RMSE está na mesma unidade do alvo (toneladas).
- **R²** — varia de $-\infty$ a 1; valores negativos indicam desempenho **pior que prever a média** do teste.
- **MAPE** — erro percentual médio; útil para comparar países com magnitudes diferentes de emissão.

Exemplos de R² por país (teste):


País	SVM (R ²)	Árvore (R ²)	SVM (MAE)	Árvore (MAE)
Brazil	0,900	-1,107	0,015 t	0,060 t
China	0,775	-19,408	0,042 t	0,432 t
United States	0,982	-0,013	0,024 t	0,246 t
India	0,992	-5,102	0,006 t	0,200 t
Iran	0,999	-16,189	0,007 t	0,800 t

Valores de R² negativos na Árvore indicam overfitting ou inadequação à curva temporal em séries curtas (~18 amostras de treino por país).

Comparação gráfica entre modelos


Os gráficos abaixo são gerados automaticamente por `step3_report.py` e salvos em `reports/figures/`. Eles estão embutidos neste README para visualização no repositório e **também aparecem no PDF** quando o README é exportado (ex.: Pandoc, extensões Markdown→PDF do VS Code/Cursor), desde que as imagens existam no caminho relativo indicado.

1. Comparativo de R² por país — SVM vs Árvore de Decisão



Barras horizontais por país; permite comparar visualmente qual modelo explica melhor a variância no período de teste.

2. Dispersão R^2 Árvore vs R^2 SVM



Cada ponto é um país. Pontos **acima da diagonal tracejada** indicam R^2 superior do SVM em relação à Árvore — o que ocorre em todos os 50 países neste experimento.

Nota: Execute `./run.sh` ou `python step3_report.py` para (re)gerar as figuras em `reports/figures/` antes de visualizar o README ou exportar o PDF, caso a pasta ainda não exista.

Arquivos de resultados detalhados

- [reports/metrics.csv](#) — MAE, MSE, RMSE, R^2 e MAPE por país e modelo
- [reports/country_summary.csv](#) — comparativo consolidado lado a lado
- [reports/ranking.csv](#) — vitórias por modelo (SVM: 50, Árvore: 0)
- [reports/best_by_country.csv](#) — melhor modelo por país
- [reports/predictions_2027.csv](#) — previsões finais para 2027

Comparação dos resultados

A análise comparativa demonstra **superioridade consistente do SVM (SVR)** em relação à Árvore de Decisão neste dataset:

1. **Cobertura:** O SVM apresentou maior R^2 em **todos os 50 países**, sem exceção (`ranking.csv`: SVM = 50 vitórias, Árvore = 0).
2. **Magnitude do erro:** O MAE médio do SVM (0,027 t) é **~12 vezes menor** que o da Árvore (0,332 t), indicando previsões substancialmente mais próximas dos valores reais no período

de teste (2022–2026).

3. **Estabilidade:** O R^2 mediano do SVM (0,981) contrasta com o R^2 mediano negativo da Árvore (−2,861). A Árvore tende a memorizar padrões do treino e falhar na generalização temporal, especialmente em países com alta variabilidade (ex.: China, $R^2 = -19,4$; Venezuela, $R^2 = -29,9$).
4. **Comportamento nas previsões de 2027:** As previsões do SVM para 2027 são coerentes com a tendência recente. Exemplos:

País	CO ₂ 2026 (obs.)	CO ₂ 2027 (previsto)
Brazil	2,11 t	2,07 t
China	8,46 t	8,52 t
United States	13,97 t	14,03 t
India	1,87 t	1,95 t

As variações previstas são suaves, compatíveis com séries temporais estáveis no curto prazo. 5. **Interpretação técnica:** O SVR com `StandardScaler` e kernel linear/RBF consegue aproximar a continuidade das séries de emissão quando combinado com lags e médias móveis. A Árvore, com poucas observações (~18 amostras de treino), tende a criar partições muito específicas que não se transferem ao período de teste posterior.

O gráfico de dispersão (*tree_vs_svm_scatter*) evidencia que praticamente todos os pontos ficam **acima da diagonal**, confirmando que o R^2 do SVM supera o da Árvore em cada nação analisada.

Conclusão

Com base nos experimentos realizados sobre o dataset `co2_emission_yearly`, conclui-se que:

- **A hipótese de que modelos não lineares seriam adequados foi parcialmente validada:** o SVM (SVR), capaz de modelar relações não lineares via kernels, obteve excelente desempenho (R^2 médio $\approx 0,93$). Porém, a Árvore de Decisão — também não linear — **não** generalizou bem neste contexto de séries temporais curtas por país.
- **O SVM é a abordagem recomendada** para predição de emissões de CO₂ per capita com este dataset. Sua combinação de normalização, margem de tolerância e seleção de hiperparâmetros via grid search produziu modelos robustos e consistentes em todos os 50 países.
- **A predição para 2027** foi realizada com o modelo SVM, gerando estimativas por país disponíveis em `reports/predictions_2027.csv`. Essas projeções devem ser interpretadas como extrapolações baseadas em tendências históricas, sujeitas a incertezas geopolíticas, econômicas e climáticas não capturadas pelos dados.
- **Trabalhos futuros** podem explorar modelos específicos para séries temporais (ARIMA, Prophet, LSTM), validação cruzada temporal (*time series cross-validation*) e inclusão de variáveis macroeconômicas adicionais para enriquecer as previsões exógenas.

Execução do projeto

```
./run.sh          # pipeline completo  
./jupyter.sh      # notebook interativo em localhost:8888
```

Documentação complementar: [\[EXPLICACAO_RESULTADOS.md\]\(./EXPLICACAO_RESULTADOS.md\)](#)